



UNIVERZITET U SARAJEVU
ELEKTROTEHNIČKI FAKULTET
ODSJEK ZA TELEKOMUNIKACIJE

QOS in unmanned aerial ad hoc network (UAANET)

KVALITETA USLUGE U TELEKOMUNIKACIJSKIM
MREZAMA

- DRUGI CIKLUS STUDIJA -

Studenti:

Ena Šabanović, Bakir Šatara, Amsal Škaljo, Hana
Španja

Mentor:

Vanr.prof.dr Miralem Mehić, dipl.ing.el.

Sarajevo,
juni 2026.

Uvod

U teorijskom dijelu ovog projekta obrađene su osnovne karakteristike UAANET mreža, njihovi ključni izazovi i pristupi kojima se pokušava ostvariti kvalitet usluge u ovakvom izrazito dinamičnom okruženju. Posebna pažnja bila je usmjerena na promjenljivost topologije, visoku mobilnost UAV čvorova, ograničene resurse uređaja, kao i na potrebu da komunikacija ostane pouzdana i dovoljno brza i onda kada se mreža često mijenja. Također su razmotreni različiti QoS modeli i rutirajući protokoli koji se u literaturi najčešće koriste za ovakve mreže.

Osnovna ideja teorijskog dijela bila je da se na jednom mjestu objedine najvažniji pojmovi potrebni za razumijevanje komunikacije u mrežama bespilotnih letjelica. Zato su prvo objašnjene specifičnosti UAANET okruženja, zatim zahtjevi koje takve mreže moraju ispuniti, a potom i razlika između reaktivnih, proaktivnih i QoS-svjesnih rutirajućih pristupa. Na taj način je postavljen temelj za praktičnu analizu, jer se tek nakon razumijevanja teorije može jasno pratiti zašto pojedini protokoli u ovakvim uslovima postižu bolje ili lošije rezultate.

Na osnovu tih teorijskih osnova, praktični dio projekta zamišljen je kao njihova simulacijska provjera. Cilj je bio da se kroz konkretan eksperiment pokaže kako se različiti rutirajući protokoli ponašaju u istom scenariju, pod istim uslovima i sa istim mrežnim parametrima.

Rad je strukturiran tako da prvo daje pregled simulacijskog okruženja i metodologije u poglavlju 1, zatim prikazuje rezultate dobijene kroz promjenu broja čvorova, brzine kretanja i modela mobilnosti u poglavlju 2, nakon čega, u poglavlju 3 slijedi poređenje sa relevantnom literaturom. Na kraju rada dat je konačan zaključak o performansama posmatrane mreže.

1. Simulacijsko okruženje i metodologija

1.1. Parametri simulacije

Simulacijski parametri odabrani su tako da odgovaraju realnom UAANET scenariju i omoguće smisleno poređenje protokola. Pri izboru parametara je vođeno računa da se što vjernije prikažu realistični scenariji, koji se u praksi mogu desiti (pokrivanje naseljenog područja pogođenog zemljotresom, nadzor farmi ili voćnjaka, potraga za nestalom osobom na nekom području). Broj čvorova, veličina prostora, brzina kretanja i trajanje simulacije izabrani su tako da mreža bude dovoljno dinamična, ali i dovoljno stabilna za mjerenje osnovnih QoS metrika.

Pri tome je posebna pažnja posvećena izboru mobilnog modela, bežičnog standarda i propagacijskog modela, jer upravo oni u velikoj mjeri određuju ponašanje mreže u simulaciji. Korišteni mobility modeli su: RandomWaypointMobilityModel, RandomWalk2dMobilityModel, GaussMarkovMobilityModel te grupni model mobilnosti kod kojeg je referentna mobilnost grupe određena RandomWaypointMobility modelom dok je mobilnost svakog člana grupe određena sa RandomWalk2dMobility modelom. Ovi modeli su odabrani zato što se često koristi u literaturi. IEEE 802.11a standard i Friis propagacijski model odabrani su jer odgovaraju scenariju sa pretpostavljenim line-of-sight (LOS) vezama, što je karakteristično za UAV mreže. Također za potrebe simulacije uveden je i RangePropagationLossModel gdje sa parametrom `txRange` možemo direktno određivati cutoff domet. Relevantni parametri simulacije prikazani su u tabelama 1.1 i 1.2.

Tablica 1.1: Parametri generisanog aplikacijskog saobraćaja

Tip saobraćaja	Veličina paketa	Brzina slanja	Model slanja
C2 kontrola	64 B	10.24 kbps	Konstantan UDP tok.
C2 komanda	128 B	20.48 kbps	Bursty UDP tok sa <code>OnTime = 0.3 s</code> i <code>OffTime = 8.0 s</code> .
Telemetrija	128 B	5.12 kbps	Konstantan UDP tok.
Image saobraćaj	1024 B	50 kbps	Bursty UDP tok sa <code>OnTime = 3.0 s</code> i <code>OffTime = 12.0 s</code> .

Tablica 1.2: Osnovni parametri simulacije

Parametar	Vrijednost	Obrazloženje
Broj UAV čvorova	5, 8, 10, 12, 15	Variran u eksperimentu skalabilnosti mreže. Bazni scenario koristi 10 UAV čvorova.
Dimenzije prostora	1000 × 1000 m	Operacijski prostor u kojem se kreću UAV čvorovi.
Položaj GCS-a	Centar simulacijskog prostora	Smanjuje uticaj nepovoljne pozicije zemaljske stanice na PDR.
Trajanje simulacije	100 s	Dovoljan period za prikupljanje QoS metrika kroz više pokretanja simulacije.
Brzina UAV čvorova	5, 10, 20, 30 m/s	Varirana u eksperimentu uticaja brzine.
Mobility modeli	RandomWaypoint, RandomWalk2D, Gauss-Markov, Group	Korišteni za poređenje različitih obrazaca kretanja UAV čvorova.
WiFi standard	IEEE 802.11a	Bežični standard u 5 GHz opsegu.
Propagacijski model	Friis + RangePropagationLossModel	LOS propagacija uz eksplicitno ograničenje komunikacijskog dometa.
Predajna snaga	20 dBm	Tipična vrijednost predajne snage bežičnog čvora.
Komunikacijski domet	~300 m	Definisan pomoću parametra <code>txRange</code> .
Transportni protokol	UDP	Pogodan za CBR i bursty aplikacijski saobraćaj.

1.2. Implementirani protokoli

U simulaciji su korištena tri nativna ns-3 rutirajuća protokola: AODV, OLSR i DSDV. Pored njih, implementirane su i dvije modificirane varijante: AODV_ETX, koji umjesto minimalnog broja hopova koristi ETX metriku, i QSPU framework, koji pri izboru rute uzima u obzir kašnjenje, povezanost i očekivano trajanje rute. Cilj poređenja je pokazati kako promjena metrike rutiranja i uvođenje QoS-svjesnih parametara može uticati na performanse UAANET mreže. Izbor ovih pet protokola omogućava poređenje reaktivnog, proaktivnog i QoS-svjesnog pristupa rutiranju u istom simulacijskom scenariju.

AODV (*Ad hoc On-Demand Distance Vector*) predstavlja reaktivni protokol koji pronalazi rutu tek kada postoji potreba za slanjem podataka. Takav pristup smanjuje kontrolni overhead, jer se rute ne održavaju stalno, ali može dovesti do većeg kašnjenja u trenutku uspostavljanja komunikacije. U osnovnoj verziji AODV najčešće bira rutu na osnovu minimalnog broja hopova, pri čemu se ne uzima direktno u obzir kvalitet bežičnih linkova.

OLSR (*Optimized Link State Routing*) je proaktivni protokol koji stalno održava informacije o mrežnoj topologiji. Zbog toga može brže reagovati pri slanju podataka, jer su

rute unaprijed poznate. Međutim, održavanje topoloških informacija zahtijeva periodičnu razmjenu kontrolnih poruka, što povećava kontrolni overhead, posebno u dinamičnim mrežama kao što su UAV ad hoc mreže.

DSDV (*Destination-Sequenced Distance Vector*) je proaktivni distance-vector protokol rutiranja. Svaki čvor održava tabelu ruta prema svim poznatim destinacijama u mreži, a svaka ruta je označena sekvencijskim brojem kako bi se spriječilo formiranje petlji i razlikovale novije informacije od starijih. Prednost DSDV protokola je u tome što su rute uglavnom dostupne bez dodatnog procesa otkrivanja, što može smanjiti inicijalno kašnjenje pri slanju paketa. Nedostatak je veći kontrolni overhead, jer se rutirajuće tabele moraju periodično ažurirati, čak i kada nema korisničkog saobraćaja.

AODV_ETX predstavlja modificiranu verziju AODV protokola u kojoj se pri izboru rute ne koristi samo minimalni broj hopova, nego ETX (*Expected Transmission Count*) metrika. ETX procjenjuje očekivani broj potrebnih transmisija za uspješan prijenos paketa preko linka, uključujući moguće retransmisije zbog gubitaka na bežičnom kanalu. Ruta sa manjom ETX vrijednošću smatra se kvalitetnijom, jer ukazuje na pouzdanije linkove i manju vjerovatnoću ponovnog slanja paketa. Na taj način AODV_ETX može izabrati rutu sa nešto većim brojem hopova ako su ti linkovi stabilniji i kvalitetniji od kraće, ali lošije rute. Ova modifikacija je posebno korisna u UAV mrežama, gdje najkraća ruta ne mora nužno biti i najbolja zbog promjenjivog kvaliteta radio-veza.

QSPU (*Quality of Service Provisioning for UAV-assisted aerial ad hoc networks*) je QoS-svjesna varijanta rutiranja zasnovana na AODV principu, ali sa dodatnim naglaskom na stabilnost rute, očekivani životni vijek veze, povezanost čvorova i smanjenje kašnjenja. Za razliku od protokola koji rutu biraju samo prema broju hopova ili dostupnosti destinacije, QSPU pokušava odabrati rutu koja je pogodnija za pouzdanu isporuku servisnog saobraćaja. Na taj način QSPU nastoji postići bolji balans između pouzdanosti komunikacije, kašnjenja, stabilnosti rute i kontrolnog opterećenja.

1.3. Topologija mreže

Simulacijska topologija zasnovana je na UAANET scenariju u kojem se UAV čvorovi kreću unutar definisanog simulacijskog prostora, dok se zemaljska kontrolna stanica, odnosno GCS (*Ground Control Station*), nalazi u centralnom dijelu područja. Simulacijski prostor je dimenzija 1000×1000 m, pri čemu se UAV čvorovi raspoređuju i kreću unutar zadatih granica prostora. Na ovaj način formirana je dinamična ad hoc mreža u kojoj se veze između UAV čvorova stalno mijenjaju zbog mobilnosti.

GCS čvor je postavljen u sredinu simulacijskog prostora kako bi se obezbijedila uravnoteženija udaljenost između zemaljske stanice i UAV čvorova. U početnim simulacijama, kada je GCS bio postavljen na rubu ili van centralnog dijela područja, značajan broj UAV čvorova je često bio izvan efektivnog komunikacijskog dometa, što je dovodilo do veoma niskog omjera uspješno isporučenih paketa. Centralnim pozicioniranjem GCS-a smanjen je ovaj problem, jer veći broj UAV čvorova tokom simulacije ima mogućnost direktne ili višeskakovne komunikacije prema GCS-u.

Ovakav izbor topologije omogućava korektnije poređenje rutirajućih protokola, jer se

smanjuje vjerovatnoća da rezultati budu dominantno određeni isključivo nepovoljnim položajem GCS-a. Umjesto toga, veći uticaj na performanse imaju svojstva samih protokola, kao što su način pronalaska ruta, održavanje ruta, izbor metrike rutiranja i otpornost na promjene topologije.

1.4. Mobility model

Za modeliranje kretanja UAV čvorova korišteno je više mobility modela dostupnih u ns-3 simulatoru. Cilj nije bio posmatrati samo jedan obrazac kretanja, nego analizirati kako različiti nivoi dinamičnosti topologije utiču na performanse rutirajućih protokola. U simulacijama su korišteni modeli `RandomWaypointMobilityModel`, `RandomWalk2dMobilityModel`, `GaussMarkovMobilityModel` i grupni model mobilnosti zasnovan na `GroupMobilityHelper` mehanizmu.

`RandomWaypointMobilityModel` predstavlja jedan od najčešće korištenih modela mobilnosti u ad hoc mrežama. Svaki UAV čvor nasumično bira novu poziciju unutar definisanog prostora, kreće se prema toj poziciji zatom brzinom, zatim kratko pauzira i ponavlja isti postupak. Ovaj model uvodi promjenljivu topologiju i omogućava jednostavnu analizu ponašanja rutirajućih protokola u uslovima nasumičnog kretanja i dinamičkog okruženja kakvo je UAANET.[1].

`RandomWalk2dMobilityModel` korišten je kao dodatni model nasumičnog kretanja. Kod ovog modela čvor periodično bira novi pravac kretanja i nastavlja kretanje unutar zadatih granica prostora. Za razliku od `RandomWaypoint` modela, gdje čvor bira krajnju tačku i kreće se prema njoj, `RandomWalk` model se zasniva na češćim promjenama pravca. Zbog toga se ovim modelom može simulirati nestabilnija topologija i češće promjene susjednih veza. Pošto je riječ o 2D modelu, kretanje se dominantno odvija u horizontalnoj ravni, dok se visinska komponenta tretira kroz inicijalni raspored i ograničenja simulacijskog prostora.

`GaussMarkovMobilityModel` korišten je zbog toga što daje glađe i realističnije promjene kretanja u odnosu na potpuno nasumične modele. Kod ovog modela buduća brzina i pravac kretanja zavise od prethodnog stanja, uz dodatnu slučajnu komponentu. Zbog toga se izbjegavaju nagle i nerealistične promjene pravca, što ga čini pogodnim za UAV mreže.

Pored pojedinačnih modela mobilnosti, korišten je i grupni model mobilnosti. Grupni model je implementiran pomoću `GroupMobilityHelper` mehanizma. Referentna tačka grupe kreće se prema `RandomWaypointMobilityModel` modelu, dok se pojedinačni članovi grupe kreću relativno u odnosu na referentnu tačku pomoću `RandomWalk2dMobilityModel` modela. Na ovaj način simulira se scenario u kojem UAV čvorovi ne djeluju potpuno nezavisno, nego se kreću kao dio grupe ili formacije, uz manje lokalne promjene položaja pojedinačnih članova.

2. Analiza simulacijskih rezultata

U ovom poglavlju prikazani su rezultati simulacija za pet analiziranih protokola rutiranja: AODV, AODV_ETX, DSDV, OLSR i QSPU. Poređenje je izvršeno na osnovu više QoS metrika, pri čemu su posebno posmatrani PDR/SSDR, prosječno kašnjenje i normalizovani routing overhead. Analiza je urađena za različite tipove aplikacijskog saobraćaja: C2 kontrolu, C2 komande, telemetriju i image saobraćaj.


U skladu sa pristupom korištenim u literaturi za UAANET mreže, PDR/SSDR se koristi kao pokazatelj uspješnosti isporuke servisnih paketa, dok se service odnosno routing overhead koristi za procjenu količine dodatnog kontrolnog saobraćaja potrebnog za održavanje komunikacije [2]. U ovoj implementaciji routing overhead je dodatno normalizovan u odnosu na isporučene aplikacijske byteove, čime se dobija jasnija slika o tome koliko kontrolnog saobraćaja protokol generiše za svaki uspješno isporučeni byte korisnog saobraćaja.

Rezultati su prikazani kroz tri eksperimenta. U prvom eksperimentu mijenja se broj UAV čvorova. U drugom eksperimentu analizira se uticaj brzine kretanja UAV čvorova. U trećem eksperimentu porede se različiti mobility modeli. Na graficima su prikazane srednje vrijednosti kroz više pokretanja simulacije, dok error barovi predstavljaju odstupanje rezultata između pojedinačnih runova. Za sve simulacije korišten je fiksni RNG seed 12345, dok su rezultati dobijeni kao prosjek kroz 10 nezavisnih pokretanja simulacije, sa vrijednostima `RngRun` od 1 do 10.

2.1. Eksperiment 1: Uticaj broja UAV čvorova

U prvom eksperimentu analiziran je uticaj broja UAV čvorova na performanse rutirajućih protokola. Broj UAV čvorova mijenjan je u rasponu od 5 do 15, dok su ostali simulacijski parametri zadržani konstantnim. Cilj ovog eksperimenta je procijeniti kako se protokoli ponašaju kada mreža postaje gušća i kada se povećava broj mogućih višeskokovnih ruta prema GCS čvoru.

2.1.1. PDR/SSDR u ovisnosti o broju čvorova



Slika 2.1: PDR/SSDR po tipu saobraćaja pri promjeni broja UAV čvorova


Slika 2.1 prikazuje PDR/SSDR za četiri tipa saobraćaja. Kod C2 kontrole i C2 komandi vidi se da AODV, AODV_ETX i QSPU ostvaruju relativno visoke vrijednosti PDR-a, posebno pri većem broju UAV čvorova. Za 5 UAV čvorova PDR je niži, jer je mreža rjeđa i postoji manji broj alternativnih ruta prema GCS čvoru. Povećanjem broja čvorova na 8, 10, 12 i 15 dolazi do poboljšanja PDR-a kod reaktivnih i QoS-svjesnih protokola, jer se povećava vjerovatnoća da postoji dostupna višeskokovna ruta.

AODV i AODV_ETX pokazuju sličan trend, pri čemu AODV_ETX u pojedinim tačkama ima nešto stabilnije ponašanje zbog korištenja ETX metrike. QSPU također ostvaruje visok PDR, naročito za C2 saobraćaj, što je u skladu sa njegovim ciljem da poboljša pouzdanost isporuke servisnih paketa u UAV mreži.

DSDV ima najniži PDR u skoro svim posmatranim slučajevima. To je očekivano, jer je riječ o proaktivnom distance-vector protokolu koji mora održavati rutirajuće tabele u mreži sa čestom promjenom topologije. OLSR pokazuje visok PDR pri manjem broju čvorova, ali se njegov rezultat ne poboljšava značajno sa povećanjem broja UAV-ova. Kod nekih tipova saobraćaja OLSR čak pokazuje blagi pad, što ukazuje da proaktivno održavanje topologije može postati manje efikasno kada se poveća dinamičnost i broj susjednih veza.

Kod telemetrije i image saobraćaja trend je sličan. AODV, AODV_ETX i QSPU generalno ostvaruju bolje rezultate od DSDV-a, dok OLSR ima dobre rezultate pri manjem broju čvorova, ali ne pokazuje isti nivo skaliranja kao reaktivni protokoli. Image saobraćaj je zahtjevniji zbog većih paketa i većeg opterećenja, pa su razlike između protokola izraženije.

2.1.2. Prosječni delay u ovisnosti o broju čvorova



Slika 2.2: Prosječni delay po tipu saobraćaja pri promjeni broja UAV čvorova


Slika 2.2 prikazuje prosječno kašnjenje za svaki tip saobraćaja. Rezultati pokazuju da QSPU u ovom eksperimentu ne ostvaruje najmanji delay. Naprotiv, kod manjeg broja čvorova QSPU ima veće kašnjenje, posebno za telemetriju i image saobraćaj. Ovo se može objasniti dodatnom logikom izbora rute i većim brojem QoS parametara koji se koriste pri odlučivanju. QSPU ne bira nužno najkraću rutu, nego rutu koja je povoljnija sa aspekta stabilnosti i servisnih parametara, što može povećati prosječno kašnjenje.

AODV i AODV_ETX imaju veće kašnjenje pri 5 UAV čvorova, ali se delay smanjuje povećanjem broja čvorova. Razlog je u tome što gušća mreža povećava vjerovatnoću pronalaska kraće ili stabilnije višeskokovne rute. Kod 10 i 12 UAV čvorova delay se značajno smanjuje za većinu tipova saobraćaja.

OLSR i DSDV imaju najmanje vrijednosti kašnjenja u većem dijelu eksperimenta. Međutim, ovaj rezultat treba tumačiti zajedno sa PDR vrijednostima. Nizak prosječni delay ne znači nužno bolju ukupnu performansu ako protokol istovremeno gubi veći broj paketa. Prosječni delay se računa samo za pakete koji su uspješno stigli na odredište, pa protokol sa većim gubicima može imati nizak delay za mali broj uspješno isporučenih paketa.

Kod image saobraćaja razlike su najizraženije. Za mali broj čvorova delay kod AODV, AODV_ETX i QSPU je značajno veći, dok se povećanjem broja čvorova smanjuje. To pokazuje da zahtjevniji saobraćaj osjetljivije reaguje na prekide ruta i rjeđu topologiju.

2.1.3. Normalizovani routing overhead



Slika 2.3: Normalizovani routing overhead po isporučenom aplikacijskom byte-u pri promjeni broja UAV čvorova

Na slici 2.3 prikazan je normalizovani routing overhead, definisan kao odnos broja routing byteova i broja uspješno isporučenih aplikacijskih byteova. Manja vrijednost ove metrike označava efikasnije korištenje mrežnih resursa, jer protokol generiše manje kontrolnog saobraćaja po jedinici korisno isporučenih podataka.

Kod AODV-a overhead raste postepeno sa povećanjem broja UAV čvorova. To je očekivano jer veći broj čvorova povećava broj mogućih promjena ruta, ali AODV ipak generiše relativno umjeren kontrolni saobraćaj. AODV_ETX ima veći overhead od standardnog AODV-a, posebno pri većem broju čvorova. Razlog je dodatno praćenje kvaliteta linkova i korištenje ETX metrike, što poboljšava informisanost pri izboru rute, ali zahtijeva dodatni kontrolni saobraćaj.

QSPU također ima veći overhead od standardnog AODV-a. To je posljedica dodatnih QoS informacija koje se koriste pri izboru rute i kontrolnih poruka potrebnih za održavanje takvog pogleda na mrežu. Ipak, overhead QSPU-a je u ovom eksperimentu niži od AODV_ETX overhead-a pri najvećem broju čvorova. Ovaj rezultat pokazuje da QSPU uvodi dodatno opterećenje, ali ono ostaje u prihvatljivom rasponu u odnosu na poboljšanje PDR-a.


OLSR i DSDV na prikazanom grafiku imaju veoma male vrijednosti normalizovanog overhead-a. Ovaj rezultat treba posmatrati u kontekstu načina mjerenja, jer je overhead izdvojen kroz port-based FlowMonitor klasifikaciju rutirajućih tokova. Zbog toga se ove vrijednosti ne smiju tumačiti kao potpuno odsustvo kontrolnog saobraćaja, nego kao vrijednost dobijena primijenjenom metodologijom mjerenja.

2.2. Eksperiment 2: Uticaj brzine UAV čvorova

U drugom eksperimentu analiziran je uticaj brzine UAV čvorova na performanse protokola. Brzina kretanja direktno utiče na stabilnost linkova i trajanje ruta. Veća brzina znači

češće promjene susjednih čvorova, češće prekide linkova i veću potrebu za ažuriranjem ruta. Zbog toga se očekuje pad PDR-a, povećanje kašnjenja i rast routing overhead-a.

2.2.1. PDR/SSDR u ovisnosti o brzini UAV čvorova



Slika 2.4: PDR/SSDR po tipu saobraćaja pri promjeni brzine UAV čvorova


Slika 2.4 pokazuje da povećanje brzine uglavnom negativno utiče na PDR/SSDR. Pri brzinama od 5 m/s i 10 m/s većina protokola ostvaruje relativno dobre rezultate, posebno za C2 kontrolu i C2 komande. Međutim, pri brzinama od 20 m/s i 30 m/s dolazi do pada PDR-a kod skoro svih protokola.

DSDV pokazuje najizraženiji pad. To je posljedica činjenice da se proaktivne rutirajuće tabele brzo zastarijevaju kada se topologija često mijenja. OLSR također gubi dio pouzdanosti pri većim brzinama, posebno za telemetriju i image saobraćaj.

AODV, AODV_ETX i QSPU bolje podnose manje i srednje brzine, ali ni oni nisu imuni na povećanje mobilnosti. QSPU pri 10 m/s postiže vrlo dobre rezultate, ali pri 30 m/s dolazi do pada PDR-a, posebno kod telemetrije i image saobraćaja. To pokazuje da QoS-svjesna metrika može poboljšati izbor rute, ali ako se topologija mijenja prebrzo, informacije o ruti mogu zastarjeti prije nego što se u potpunosti iskoriste.

Kod image saobraćaja pad PDR-a je izraženiji nego kod C2 saobraćaja. Razlog je veće opterećenje i veća veličina paketa, zbog čega prekidi linkova imaju veći uticaj na uspješnost isporuke.

2.2.2. Prosječni delay u ovisnosti o brzini UAV čvorova



Slika 2.5: Prosječni delay po tipu saobraćaja pri promjeni brzine UAV čvorova


Na slici 2.5 vidi se da povećanje brzine uglavnom povećava prosječni delay kod AODV, AODV_ETX i QSPU protokola. Ovaj trend je posebno izražen za telemetriju i image saobraćaj pri brzini od 30 m/s. Veća brzina dovodi do češćih prekida ruta, pa protokoli moraju češće pokretati procese otkrivanja ili ažuriranja ruta. To direktno povećava vrijeme potrebno da paket stigne do odredišta.

QSPU ima najveći delay kod većih brzina, naročito za telemetriju i image saobraćaj. Ovaj rezultat ukazuje na cijenu QoS-svjesnog pristupa. QSPU pokušava pronaći stabilniju i kvalitetniju rutu, ali pri visokoj mobilnosti takva odluka može zahtijevati više kontrolnih informacija i može dovesti do većeg kašnjenja.

AODV_ETX također pokazuje rast delay-a pri većim brzinama. ETX metrika zavisi od procjene kvaliteta linkova, a kod brze mobilnosti kvalitet linka se brzo mijenja. Zbog toga ruta koja je u jednom trenutku procijenjena kao dobra može brzo postati lošija.

OLSR i DSDV imaju relativno male vrijednosti delay-a, ali kao i u prethodnom eksperimentu, ovaj rezultat treba posmatrati zajedno sa PDR-om. Nizak delay uz nizak PDR znači da su brzo isporučeni samo paketi koji su pronašli dostupnu rutu, dok izgubljeni paketi ne ulaze u prosjek kašnjenja.

2.2.3. Normalizovani routing overhead u ovisnosti o brzini



Slika 2.6: Normalizovani routing overhead po isporučenom aplikacijskom byte-u pri promjeni brzine UAV čvorova

Slika 2.6 pokazuje da routing overhead raste sa povećanjem brzine UAV čvorova. AODV ima najniži overhead među protokolima kod kojih je routing overhead jasno izražen, dok AODV_ETX i QSPU generišu više kontrolnog saobraćaja.


AODV_ETX ima izražen rast overhead-a pri 20 m/s i 30 m/s. To je očekivano, jer se pri većoj mobilnosti češće mijenja kvalitet linkova, pa ETX metrika zahtijeva dodatno ažuriranje informacija o susjednim vezama. QSPU također ima povećan overhead, jer mora održavati dodatne QoS informacije koje se odnose na stabilnost, kašnjenje i pogodnost rute.

Ovaj eksperiment pokazuje osnovni kompromis između kvaliteta rutiranja i dodatnog kontrolnog opterećenja. Jednostavniji protokoli, kao što je AODV, imaju manji overhead, ali manje informacija za izbor rute. Napredniji protokoli, kao AODV_ETX i QSPU, imaju bolju osnovu za donošenje odluka, ali generišu veći kontrolni saobraćaj.

2.3. Eksperiment 3: Uticaj mobility modela

U trećem eksperimentu analiziran je uticaj različitih mobility modela na performanse rutirajućih protokola. Korišteni su RandomWaypoint, RandomWalk2D, Gauss-Markov i Group mobility model. Ovaj eksperiment je važan jer rezultati u UAV mrežama ne zavise samo od protokola, nego i od načina kretanja čvorova. Različiti mobility modeli proizvode različite obrasce prekida linkova, promjene susjedstva i trajanja ruta.

2.3.1. PDR/SSDR za različite mobility modele



Slika 2.7: PDR/SSDR po tipu saobraćaja za različite mobility modele


Slika 2.7 pokazuje da mobility model ima značajan uticaj na PDR/SSDR. RandomWaypoint daje najbolje ili među najboljim rezultate za većinu protokola. To je očekivano, jer ovaj model daje relativno ravnomjerno kretanje kroz prostor i omogućava formiranje stabilnijih višeskokovnih ruta u odnosu na modele sa češćim promjenama pravca.

RandomWalk2D značajno smanjuje PDR kod AODV, AODV_ETX, DSDV i QSPU protokola. Kod ovog modela čvorovi češće mijenjaju pravac, što povećava vjerovatnoću prekida linkova i dovodi do nestabilnijih ruta. OLSR u ovom eksperimentu pokazuje relativno stabilan PDR kroz različite mobility modele, što ukazuje da proaktivno održavanje topologije u nekim scenarijima može pomoći održavanju isporuke paketa.

Gauss-Markov model daje srednje rezultate. Kod nekih tipova saobraćaja PDR se poboljšava u odnosu na RandomWalk2D, jer Gauss-Markov uvodi glade promjene kretanja. Međutim, kod većeg opterećenja i kod protokola koji zavise od procjene stanja rute, i dalje se javljaju gubici.

Group mobility model daje mješovite rezultate. Kod nekih protokola grupno kretanje može pomoći, jer se čvorovi kreću koordinisano i duže ostaju u međusobnoj blizini. Međutim, kod QSPU-a se vidi veća varijabilnost, posebno za telemetriju i image saobraćaj. To znači da grupna topologija može biti povoljna ako grupa ostaje dobro povezana sa GCS-om, ali može postati nepovoljna ako se veći dio grupe udalji ili ako se formira lošija višeskokovna struktura.

2.3.2. Prosječni delay za različite mobility modele



Slika 2.8: Prosječni delay po tipu saobraćaja za različite mobility modele


Slika 2.8 prikazuje da Gauss-Markov model uzrokuje najveći delay za AODV, AODV_ETX i QSPU, posebno kod telemetrije i image saobraćaja. Iako Gauss-Markov daje glade kretanje, takvo kretanje može dovesti do situacija u kojima se čvorovi duže zadržavaju u nepovoljnim prostornim konfiguracijama. Ako se formiraju duže ili opterećenije rute, prosječno kašnjenje raste.

Kod RandomWaypoint modela delay je relativno umjeren, posebno za C2 saobraćaj. RandomWalk2D daje manje kašnjenje od Gauss-Markov modela kod većine protokola, ali to ne znači da je ukupno bolji, jer PDR rezultati pokazuju značajan pad isporuke paketa.

Group mobility daje različite rezultate u zavisnosti od protokola i tipa saobraćaja. Kod image saobraćaja AODV i AODV_ETX imaju veći delay, dok QSPU pokazuje manji delay, ali uz niži PDR. Ovaj rezultat pokazuje da delay nikada ne treba analizirati izolovano. Protokol može imati nizak delay ako isporučuje samo manji broj paketa, dok se veći broj paketa izgubi.

OLSR u ovom eksperimentu ima najniže vrijednosti delay-a za većinu mobility modela i tipova saobraćaja. Međutim, kao i ranije, taj rezultat treba porediti sa PDR-om i overhead-om, jer nizak delay sam po sebi ne garantuje bolji QoS.

2.3.3. Normalizovani routing overhead za različite mobility modele



Slika 2.9: Normalizovani routing overhead po isporučenom aplikacijskom byte-u za različite mobility modele

Na slici 2.9 prikazan je normalizovani routing overhead za različite mobility modele. Kod RandomWaypoint, RandomWalk2D i Gauss-Markov modela overhead ostaje relativno nizak za sve protokole, iako QSPU i AODV_ETX imaju nešto veće vrijednosti od AODV-a. To je očekivano zbog dodatnih informacija koje koriste pri izboru rute.

Najveće odstupanje se javlja kod Group mobility modela, gdje QSPU pokazuje značajno veći overhead i veliku varijabilnost između runova. Ovo ukazuje da grupno kretanje može stvarati situacije u kojima QSPU generiše više kontrolnih poruka kako bi održao QoS informacije i pokušao pronaći pogodnu rutu. Veliki error bar pokazuje da rezultat jako zavisi od konkretne prostorne konfiguracije grupe u pojedinačnom runu.

AODV_ETX također ima povećan overhead kod Group modela, ali manje izražen nego QSPU. Standardni AODV ostaje najjednostavniji po pitanju kontrolnog opterećenja. DSDV i OLSR ponovo imaju vrlo male vrijednosti u ovoj metrici, što je potrebno tumačiti u skladu sa načinom mjerenja routing overhead-a.

3. Poređenje sa literaturom

Dobijeni simulacijski rezultati upoređeni su sa zaključcima iz radova Maxa et al. [3] i Kim et al. [1]. Cilj ovog poređenja nije potpuno numeričko poklapanje, jer simulacijski scenariji, broj čvorova, veličina prostora, tipovi saobraćaja i korišteni mobility modeli nisu identični. Umjesto toga, posmatra se da li dobijeni rezultati prate očekivane trendove iz literature za UAANET/FANET mreže.

Maxa et al. naglašavaju da se UAANET mreže razlikuju od klasičnih MANET mreža zbog veće mobilnosti, čestih promjena topologije, potrebe za multi-hop komunikacijom i važnosti C2 i payload saobraćaja [3]. U istom radu se navodi da rutirajući protokol u UAANET mreži mora omogućiti otkrivanje ruta, prosljeđivanje podataka i održavanje ruta u uslovima stalnih promjena topologije. Ovi zaključci su potvrđeni i u našim rezultatima, jer se promjena broja UAV čvorova, brzine kretanja i mobility modela direktno odrazila na PDR/SSDR, delay i routing overhead.

Najbliže direktno poređenje moguće je sa radom Kim et al. [1], gdje su analizirani AODV, DSDV i OLSR u ns-3 FANET scenariju. U tom radu AODV postiže najbolji PDR, približno 81% za SRWP mobility model, dok DSDV ima slabije rezultate zbog potrebe za stalnim ažuriranjem rutirajućih tabela. Sličan trend je dobijen i u ovom radu. U eksperimentu sa promjenom broja čvorova AODV za 15 UAV čvorova ostvaruje približno 90% PDR-a. DSDV je u istom eksperimentu znatno slabiji i uglavnom se kreće oko 60–65%, što je u skladu sa zaključkom da proaktivni distance-vector pristup slabije podnosi česte promjene topologije.

Rezultati za OLSR su djelimično u skladu sa literaturom. Kim et al. navode da OLSR može imati dobro kašnjenje, ali da AODV generalno daje bolji PDR u scenarijima gdje je pouzdana isporuka paketa važnija od samog vremena isporuke [1]. U našim rezultatima OLSR često ima vrlo nizak prosječni delay, naročito kod C2 i telemetrijskog saobraćaja. Međutim, njegov PDR pri većem broju čvorova ne raste kao kod AODV-a i AODV_ETX-a. Na primjer, za 15 UAV čvorova OLSR ostvaruje približno 75% PDR-a, što je niže od AODV-a i AODV_ETX-a. Zbog toga se može zaključiti da je OLSR dobar kada je prioritet mali delay, ali ne i kada je glavni cilj maksimalna isporuka paketa.

Uvođenjem ETX metrike AODV_ETX ne bira rutu samo prema broju hopova, nego uzima u obzir i kvalitet linka. U našim rezultatima AODV_ETX postiže PDR vrlo blizak AODV-u: za 15 UAV čvorova približno 90%. Međutim, cijena ove modifikacije vidi se u routing overhead-u. Normalizovani routing overhead kod AODV_ETX-a raste sa brojem čvorova i pri 15 UAV čvorova dostiže približno 0.056 routing byte/app byte, dok je kod AODV-a oko 0.020 routing byte/app byte. To potvrđuje očekivani kompromis: kvalitativnija metrika rutiranja može poboljšati izbor rute, ali uvodi dodatni kontrolni saobraćaj.

QSPU je uveden kao QoS-svjestan pristup, pa se ne očekuje nužno najmanji delay ili

najmanji overhead, nego bolji balans između pouzdanosti isporuke, stabilnosti rute i servisnog opterećenja. U originalnom radu [2] prikazano je jako dobro ponašanje QSPU u odnosu na konkurente. Međutim u tim eksperimentima je vršena simulacija sa velikim brojem UAV čvorova gdje jedan ovakav framework dolazi do izražaja. U našem slučaju malih/srednjih UAV ad-hoc mreža ovaj framework ne daje najbolje rezultate. U eksperimentu sa promjenom broja čvorova QSPU ostvaruje visok PDR za C2 saobraćaj, oko 90–92% pri 15 UAV čvorova, ali ima veći delay od jednostavnijih protokola. Također, njegov normalizovani routing overhead pri 15 UAV čvorova iznosi približno 0.035 routing byte/app byte, što je više od AODV-a, ali niže od AODV_ETX-a u istom slučaju. Ovakav rezultat pokazuje da QSPU uvodi dodatnu cijenu zbog QoS logike, ali ta cijena nije ekstremna u odnosu na dobijenu pouzdanost C2 saobraćaja.

Uticaj brzine UAV čvorova također se poklapa sa očekivanjima iz literature. Kim et al. naglašavaju da mobilnost, brzina i položaj GCS-a mogu značajno promijeniti performanse FANET protokola [1]. U našim rezultatima povećanje brzine sa 5 m/s na 30 m/s uglavnom smanjuje PDR i povećava delay.

Posebno važan rezultat je uticaj mobility modela. Kim et al. pokazuju da se performanse rutiranja značajno mijenjaju u zavisnosti od modela kretanja i da položaj GCS-a ima veliki uticaj na PDR [1]. U ovom radu se isti zaključak vidi kroz poređenje RandomWaypoint, RandomWalk2D, Gauss-Markov i Group mobility modela. RandomWaypoint daje najbolje rezultate za većinu protokola, pri čemu AODV, AODV_ETX i QSPU postižu oko 80–85% PDR-a za većinu tipova saobraćaja. Kod RandomWalk2D modela PDR značajno pada, često na oko 40–45% za AODV, AODV_ETX i QSPU. Group model daje promjenjive rezultate i veći routing overhead kod QSPU-a, što pokazuje da grupno kretanje može biti povoljno samo ako grupa ostaje dobro povezana sa GCS-om.

Ukupno posmatrano, dobijeni rezultati su u skladu sa glavnim zaključcima iz literature. Kao i kod Kim et al., AODV se pokazuje kao vrlo dobar osnovni protokol za FANET/UAANET scenarije, posebno kada je PDR glavna metrika. OLSR ima prednost u pogledu malog kašnjenja, ali ne postiže uvijek visok PDR. DSDV pokazuje slabije ponašanje u dinamičnoj mreži. Modificirani protokoli, AODV_ETX i QSPU, uvode dodatne informacije pri izboru rute i mogu dati bolju pouzdanost u pojedinim scenarijima, ali uz veći routing overhead. Zbog toga se potvrđuje osnovni zaključak iz literature: u UAANET mrežama ne postoji jedan protokol koji je najbolji po svim metrikama, nego izbor protokola zavisi od prioriteta konkretne misije, odnosno od toga da li je važnija pouzdanost isporuke, manje kašnjenje ili manji kontrolni overhead.

Zaključak

U ovom radu analizirane su performanse rutirajućih protokola u UAANET okruženju korištenjem ns-3 simulatora. Poređeni su AODV, AODV_ETX, DSDV, OLSR i QSPU protokoli kroz tri eksperimenta: promjenu broja UAV čvorova, promjenu brzine kretanja i promjenu mobility modela. Kao glavne metrike korišteni su PDR/SSDR, prosječno kašnjenje i normalizovani routing overhead.

Dobijeni rezultati pokazuju da AODV ostvaruje dobar balans između pouzdanosti isporuke, kašnjenja i kontrolnog opterećenja. AODV_ETX postiže slične vrijednosti PDR-a kao AODV, ali uz veći routing overhead zbog praćenja kvaliteta linkova kroz ETX metriku. DSDV je u većini scenarija ostvario najniži PDR, što pokazuje da proaktivno održavanje rutirajućih tabela nije najpogodnije za dinamične UAV mreže. OLSR ima relativno nizak delay, ali ne postiže uvijek visok PDR.

QSPU se pokazao kao QoS-svjestan protokol koji može ostvariti visok PDR, posebno za C2 saobraćaj, ali uz cijenu većeg prosječnog kašnjenja i većeg routing overhead-a. Zbog toga se QSPU ne može posmatrati kao najbolje rješenje po svim metrikama, nego kao kompromis između pouzdanosti isporuke, stabilnosti rute i dodatnog kontrolnog opterećenja.

Rezultati također pokazuju da broj čvorova, brzina kretanja i mobility model značajno utiču na performanse UAANET mreže. Povećanje brzine uglavnom smanjuje PDR i povećava kašnjenje, dok različiti mobility modeli daju različite nivoe stabilnosti ruta. Na osnovu provedene analize može se zaključiti da izbor protokola zavisi od prioriteta misije: AODV je dobar osnovni izbor, OLSR je pogodan kada je važan nizak delay, dok AODV_ETX i QSPU imaju smisla kada se želi uzeti u obzir kvalitet linka i QoS parametri. Budući rad može uključiti veći broj UAV čvorova, dodatne metrike poput jittera i energetske potrošnje, kao i detaljniju analizu skalabilnosti.

Bibliografija

- [1] T. Kim, S. Lee, K. H. Kim, and Y.-I. Jo. Fanet routing protocol analysis for multi-uav-based reconnaissance mobility models. *Analysis of Routing Protocols for Multi-UAV FANET Reconnaissance Scenarios*, 2023.
- [2] Kirshna Kumar, Sushil Kumar, Omprakash Kaiwartya, Ajay Sikandar, Rupak Kharel, and Jaime Lloret Mauri. Internet of unmanned aerial vehicles: Qos provisioning in aerial ad-hoc networks. *Sensors*, 20(11):3160, 2020. doi: 10.3390/s20113160.
- [3] J.-A. Maxa, M.-S. Ben Mahmoud, and N. Larrieu. Survey on uaanet routing protocols and network security challenges. *Ad Hoc & Sensor Wireless Networks*, 2017. URL <https://enac.hal.science/hal-01465993/document>.
- [4] I. Bekmezci, O. K. Sahingoz, and S. Temel. Flying ad-hoc networks (fanets): A survey. *Ad Hoc Networks*, 11(3):1254–1270, 2013. doi: 10.1016/j.adhoc.2012.12.004.
- [5] J.-A. Maxa, N. Larrieu, and P. Roux. Emulation-based performance evaluation of routing protocols for uaanets. In *Ad-hoc, Mobile, and Wireless Networks – ADHOC-NOW 2015*, volume 9143 of *Lecture Notes in Computer Science*, pages 227–241, Cham, 2015. Springer. doi: 10.1007/978-3-319-17765-6_20.
- [6] O. Bouachir, F. Garcia, N. Larrieu, and T. Gayraud. Ad hoc network qos architecture for cooperative unmanned aerial vehicles (uavs). In *Conference Paper*, 2014.
- [7] ns-3 Consortium. ns-3: A discrete-event network simulator for internet systems, 2024. URL <https://www.nsnam.org/>.
- [8] M. Mehić. Kvaliteta usluga u telekomunikacijama – predavanje 4, 2026.